

第12讲 | Java有几种文件拷贝方式？哪一种最高效？

2018-05-31 杨晓峰



第12讲 | Java有几种文件拷贝方式？哪一种最高效？

杨晓峰

- 00:00 / 12:38

我在专栏上一讲提到，NIO不止是多路复用，NIO 2也不只是异步IO，今天我们来看看Java IO体系中，其他不可忽略的部分。

今天我要问你的问题是，**Java有几种文件拷贝方式？哪一种最高效？**

典型回答

Java有多种比较典型的文件拷贝实现方式，比如：

利用Java.io类库，直接为源文件构建一个FileInputStream读取，然后再为目标文件构建一个FileOutputStream，完成写入工作。

```
public static void copyFileByStream(File source, File dest) throws
    IOException {
    try (InputStream is = new FileInputStream(source);
        OutputStream os = new FileOutputStream(dest));{
        byte[] buffer = new byte[1024];
        int length;
        while ((length = is.read(buffer)) > 0) {
            os.write(buffer, 0, length);
        }
    }
}
```

或者，利用java.nio类库提供的transferTo或transferFrom方法实现。

```
public static void copyFileByChannel(File source, File dest) throws
    IOException {
    try (FileChannel sourceChannel = new FileInputStream(source)
        .getChannel();
        FileChannel targetChannel = new FileOutputStream(dest).getChannel
        ());{
        for (long count = sourceChannel.size(); count > 0; ) {
            long transferred = sourceChannel.transferTo(
                sourceChannel.position(), count, targetChannel);
            count -= transferred;
        }
    }
}
```

当然，Java标准类库本身已经提供了几种Files.copy的实现。

对于Copy的效率，这个其实与操作系统和配置等情况相关，总体上来说，NIO transferTo/From的方式可能更快，因为它更能利用现代操作系统底层机制，避免不必要拷贝和上下文切换。

考点分析

今天这个问题，从面试的角度来看，确实是一个面试考察的点，针对我上面的典型回答，面试官还可能会从实践角度，或者IO底层实现机制等方面进一步提问。这一讲的内容从面试题出发，主要还是为了让你进一步加深对Java IO类库设计和实现的了解。

从实践角度，我前面并没有明确说NIO transfer的方案一定最快，真实情况也确实未必如此。我们可以根据理论分析给出可行的推断，保持合理的怀疑，给出验证结论的思路，有时候面试官考察的就是如何将猜测变成可验证的结论，思考方式远比记住结论重要。

从技术角度展开，下面这些方面值得注意：

- 不同的copy方式，底层机制有什么区别？
- 为什么零拷贝（zero-copy）可能有性能优势？
- Buffer分类与使用。
- Direct Buffer对垃圾收集等方面的影响与实践选择。

接下来，我们一起来分析一下吧。

知识扩展

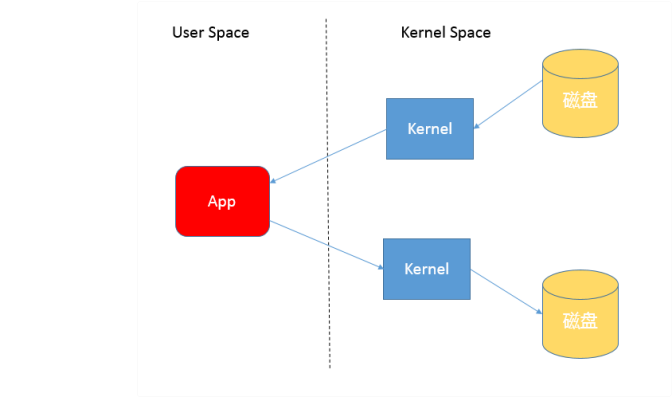
1.拷贝实现机制分析

先来理解一下，前面实现的不同拷贝方法，本质上有什么明显的区别。

首先，你需要理解用户态空间（User Space）和内核态空间（Kernel Space），这是操作系统层面的基本概念，操作系统内核、硬件驱动等运行在内核态空间，具有相对高的特权；而用户态空间，则是给普通应用和服务使用。你可以参考：https://en.wikipedia.org/wiki/User_space。

当我们使用输入输出流进行读写时，实际上是进行了多次上下文切换，比如应用读取数据时，先在内核态将数据从磁盘读取到内核缓存，再切换到用户态将数据从内核缓存读取到用户缓存。

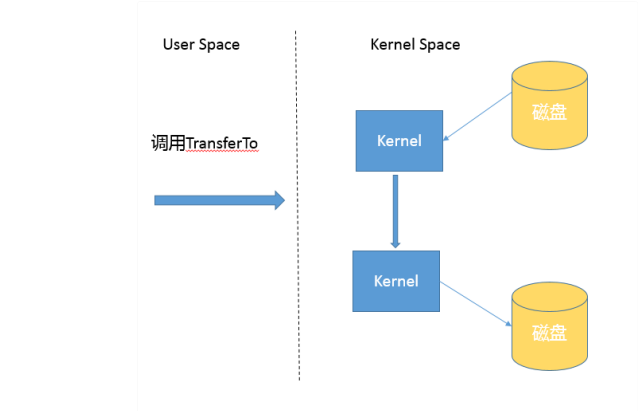
写入操作也是类似，仅仅是步骤相反，你可以参考下面这张图。



所以，这种方式会带来一定的额外开销，可能会降低IO效率。

而基于NIO transferTo的实现方式，在Linux和Unix上，则会使用到零拷贝技术，数据传输并不需要用户态参与，省去了上下文切换的开销和不必要的内存拷贝，进而可能提高应用拷贝性能。注意，transferTo不仅仅是可以用在文件拷贝中，与其类似的，例如读取磁盘文件，然后进行Socket发送，同样可以享受这种机制带来的性能和扩展性提高。

transferTo 的传输过程是：



2.Java IO/NIO源码结构

前面我在典型回答中提了第三种方式，即Java标准库也提供了文件拷贝方法（`java.nio.file.Files.copy`）。如果你这样回答，就一定要小心了，因为很少有问题的答案是仅仅调用某个方法。从面试的角度，面试官往往会追问：既然你提到了标准库，那么它是怎么实现的呢？有的公司面试官以喜欢追问而出名，直到追问到你说不知道。

其实，这个问题的答案还真不是那么直观，因为实际上有几个不同的copy方法。

```
public static Path copy(Path source, Path target, CopyOption... options)
    throws IOException
```

```
public static long copy(InputStream in, Path target, CopyOption... options)
    throws IOException
```

```
public static long copy(Path source, OutputStream out)
    throws IOException
```

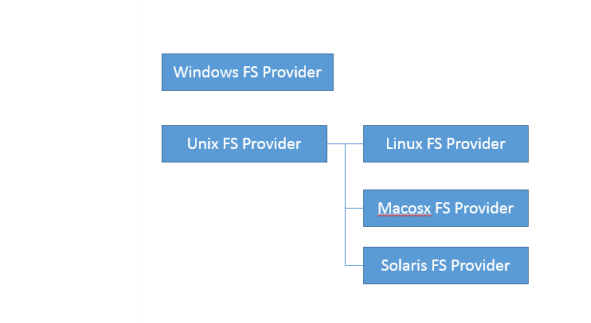
可以看到，copy不仅仅是支持文件之间操作，没有人限定输入输出流一定是针对文件的，这是两个很实用的工具方法。

后面两种copy实现，能够在方法实现里直接看到使用的是`InputStream.transferTo()`，你可以直接看源码，其内部实现其实是stream在用户态的读写；而对于第一种方法的分析过程要相对麻烦一些，可以参考下面片段。简单起见，我只分析同类型文件系统拷贝过程。

```
public static Path copy(Path source, Path target, CopyOption... options)
    throws IOException
{
    FileSystemProvider provider = provider(source);
    if (provider(target) == provider) {
        // same provider
        provider.copy(source, target, options); // 这是本文分析的路径
    } else {
        // different providers
        CopyMoveHelper.copyToForeignTarget(source, target, options);
    }
    return target;
}
```

我把源码分析过程简单记录如下，JDK的源代码中，内部实现和公共API定义也不是可以能够简单关联上的，NIO部分代码甚至是定义为模板而不是Java源文件，在build过程自动生成源码，下面顺便介绍一下部分JDK代码机制和如何绕过隐藏障碍。

- 首先，直接跟踪，发现`FileSystemProvider`只是个抽象类，阅读它的[源码](#)能够理解到，原来文件系统实际逻辑存在于JDK内部实现里，公共API其实是通过`ServiceLoader`机制加载一系列文件系统实现，然后提供服务。
- 我们可以在JDK源码里搜索`FileSystemProvider`和`nio`，可以定位到[sun/nio/fs](#)，我们知道NIO底层是和操作系统紧密相关的，所以每个平台都有自己的部分特有文件系统逻辑。



- 省略掉一些细节，最后我们一步步定位到`UnixFileSystemProvider` → `UnixCopyFile.Transfer`，发现这是个本地方法。
- 最后，明确定位到[UnixCopyFile.c](#)，其内部实现清楚说明竟然只是简单的用户态空间拷贝！

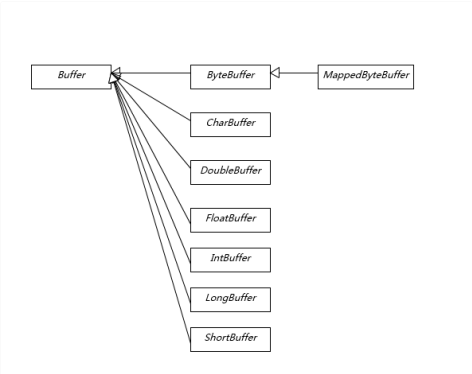
所以，我们明确这个最常见的copy方法其实不是利用transferTo，而是本地技术实现的用户态拷贝。

前面谈了不少机制和源码，我简单从实践角度总结一下，如何提高类似拷贝等IO操作的性能，有一些宽泛的原则：

- 在程序中，使用缓存等机制，合理减少IO次数（在网络通信中，如TCP传输，window大小也可以看作是类似思路）。
- 使用transferTo等机制，减少上下文切换和额外IO操作。
- 尽量减少不必要的转换过程，比如编解码；对对象序列化和反序列化，比如操作文本文件或者网络通信，如果不是过程中需要使用文本信息，可以考虑不要将二进制信息转换成字符串，直接传输二进制信息。

3. 掌握NIO Buffer

我在上一讲提到Buffer是NIO操作数据的基本工具，Java为每种原始数据类型都提供了相应的Buffer实现（布尔除外），所以掌握和使用Buffer是十分必要的，尤其是涉及Direct Buffer等使用，因为其在垃圾收集等方面的特殊性，更要重点掌握。



Buffer有几个基本属性：

- capacity，它反映这个Buffer到底有多大，也就是数组的长度。
- position，要操作的数据起始位置。
- limit，相当于操作的限额。在读取或者写入时，limit的意义很明显是不一样的。比如，读取操作时，很可能将limit设置到所容纳数据的上限；而在写入时，则会设置容量或容量以下的可写限度。
- mark，记录上一次position的位置，默认是0，算是一个便利性的考虑，往往不是必须的。

前面三个是我们日常使用最频繁的，我简单梳理下Buffer的基本操作：

- 我们创建了一个ByteBuffer，准备放入数据，capacity当然就是缓冲区大小，而position就是0，limit默认就是capacity的大小。
- 当我们写入几个字节的数据时，position就会跟着水涨船高，但是它不可能超过limit的大小。
- 如果我们想把前面写入的数据读出来，需要调用flip方法，将position设置为0，limit设置为以前的position那里。
- 如果还想从头再读一遍，可以调用rewind，让limit不变，position再次设置为0。

更进一步的详细使用，我建议参考相关[教程](#)。

4.Direct Buffer和垃圾收集

我这里重点介绍两种特别的Buffer。

- Direct Buffer：如果我们看Buffer的方法定义，你会发现它定义了isDirect()方法，返回当前Buffer是否是Direct类型。这是因为Java提供了堆内和堆外（Direct）Buffer，我们可以以它的allocate或者allocateDirect方法直接创建。
- MappedByteBuffer：它将文件按照指定大小直接映射为内存区域，当程序访问这个内存区域时将直接操作这块儿文件数据，省去了将数据从内核空间向用户空间传输的损耗。我们可以使用[FileChannel.map](#)创建MappedByteBuffer，它本质也是种Direct Buffer。

在实际使用中，Java会尽量对Direct Buffer仅做本地IO操作，对于很多大数据量的IO密集操作，可能会带来非常大的性能优势，因为：

- Direct Buffer生命周期内内存地址都不会再发生变更，进而内核可以安全地对其进行访问，很多IO操作会很高效。
- 减少了堆内对象存储的可能额外维护工作，所以访问效率可能有所提高。

但是请注意，Direct Buffer创建和销毁过程中，都会比一般的堆内Buffer增加部分开销，所以通常都建议用于长期使用、数据较大的场景。

使用Direct Buffer，我们需要清楚它对内存和JVM参数的影响。首先，因为它不在堆上，所以Xmx之类参数，其实并不能影响Direct Buffer等堆外成员所使用的内存额度，我们可以使用下面参数设置大小：

```
-XX:MaxDirectMemorySize=512M
```

从参数设置和内存问题排查角度来看，这意味着我们在计算Java可以使用的内存大小的时候，不能只考虑堆的需要，还有Direct Buffer等一系列堆外因素。如果出现内存不足，堆外内存占用也是一种可能性。

另外，大多数垃圾收集过程中，都不会主动收集Direct Buffer，它的垃圾收集过程，就是基于我在专栏前面所介绍的Cleaner（一个内部实现）和幻影引用（PhantomReference）机制，其本身不是public类型，内部实现了一个Deallocator负责销毁的逻辑。对它的销毁往往要拖到full GC的时候，所以使用不当很容易导致OutOfMemoryError。

对于Direct Buffer的回收，我有几个建议：

- 在应用程序中，显式地调用System.gc()来强制触发。
- 另外一种思路是，在大量使用Direct Buffer的部分框架中，框架会自己在程序中调用释放方法，Netty就是这么做的，有兴趣可以参考其实现（PlatformDependent0）。
- 重复使用Direct Buffer。

5.跟踪和诊断Direct Buffer内存占用？

因为通常の垃圾收集日志等记录，并不包含Direct Buffer等信息，所以Direct Buffer内存诊断也是个比较头疼的事情。幸好，在JDK 8之后的版本，我们可以方便地使用Native Memory Tracking（NMT）特性来进行诊断，你可以在程序启动时加上下面参数：

```
-XX:NativeMemoryTracking={summary|detail}
```

注意，激活NMT通常都会导致JVM出现5%~10%的性能下降，请谨慎考虑。

运行时，可以采用下面命令进行交互式对比：

```
// 打印NMT信息
jcmd <pid> VM.native_memory detail

// 进行baseline，以对比分配为存变化
jcmd <pid> VM.native_memory baseline

// 进行baseline，以非比分配为存变化
jcmd <pid> VM.native_memory detail.diff
```

我们可以在Internal部分发现Direct Buffer内存使用的信息，这是因为其底层实际是利用unsafe_allocatememory。严格说，这不是JVM内部使用的内存，所以在JDK 11以后，其实它是归类在other部分里。

JDK 9的输出片段如下，“+”表示的就是diff命令发现的分配变化：

```
-Internal (reserved=679KB +4KB, committed=679KB +4KB)
      (malloc=615KB +4KB #1571 +4)
      (mmap: reserved=64KB, committed=64KB)
```

注意：JVM的堆外内存远不止Direct Buffer，NMT输出的信息当然也远不止这些，我在专栏后面有综合分析更加具体的内存结构的主题。

今天我分析了Java IO/NIO底层文件操作数据的机制，以及如何实现零拷贝的高性能操作，梳理了Buffer的使用和类型，并针对Direct Buffer的生命周期管理和诊断进行了较详细的分析。

一课一练

关于今天我们讨论的题目你做到心中有数了吗？你可以思考下，如果我们需要在channel读取的过程中，将不同片段写入到相应的Buffer里面（类似二进制消息分拆成消息头、消息体等），可以采用NIO的什么机制做到呢？

请在留言区写写你对这个问题的思考，我会选出经过认真思考的留言，送给你一份学习鼓励金，欢迎你与我一起讨论。

你的朋友是不是也在准备面试呢？你可以“请朋友读”，把今天的题目分享给好友，或许你能帮到他。



13576788017	
杨老师，想问一下，一般要几年java经验才能达到看懂你文章的地步？？我将近一年经验。。我发现我好几篇都看不懂。。底层完全不懂。。是我太菜了吗。。	2018-05-31
作者回复	
非常抱歉，具体哪几篇？公司对一年经验的工程师要求应该也不一样的	2018-05-31
行者	
可以利用NIO分散-scatter机制来写入不同buffer。 Code: ByteBuffer header = ByteBuffer.allocate(128); ByteBuffer body = ByteBuffer.allocate(1024); ByteBuffer[] bufferArray = {header, body}; channel.read(bufferArray); 注意:该方法适用于请求头长度固定。	2018-05-31
作者回复	
赞	

石头狮子	2018-05-31
若使用非 <code>directbuffer</code> 操作相关 <code>api</code> 的话, <code>jdk</code> 会将其复制为 <code>directbuff</code> , 并且在线程内部缓存该 <code>directbuffer</code> 。 <code>jdk</code> 对这个缓存的大小并没有限制。之前遇到缓存的 <code>directbuffer</code> 过多, 导致oom的情况。后续 <code>jdk</code> 版本加入了对该缓存的限制。额外一点是尽量不要使用堆内的 <code>bytebuffer</code> 操作 <code>channel</code> 类 <code>api</code> 。	
vash_ace	2018-06-01
其实在初始化 <code>DirectByteBuffer</code> 对象时, 如果当前堆外内存的条件很苛刻时, 会主动调用 <code>System.gc()</code> 强制执行F GC。所以一般建议在使用 <code>netty</code> 时开启XX: +DisableExplicitGC	
作者回复	2018-06-01
对, 检测不够时会尝试 <code>system.gc</code> , 记得老版本有开发分配bug, 会出oom, <code>netty</code> 文中提到了, 它是hack到内部自己释放...	
乘风破浪	2018-05-31
零拷贝是不是可以理解为核心态空间与磁盘之间的数据传输, 不需要再经过用户态空间?	
作者回复	2018-06-01
嗯	
闭门车	2018-06-06
你好, 我查看jdk8中的源码, 看到您说的关于 <code>Files.copy</code> 其中两种是依靠 <code>transferto</code> 实现的, 但是我翻看源码觉得跟您的理解不同, 特来求证, 源码如下: <code>public static long copy(Path source, OutputStream out) throws IOException { Objects.requireNonNull(out); try {InputStream in = newInputStream(source)} { return copy(in, out); } } private static long copy(InputStream source, OutputStream sink) throws IOException { { long nread = 0L; byte[] buf = new byte[BUFFER_SIZE]; int n; while ((n = source.read(buf)) > 0) { sink.write(buf, 0, n); nread += n; } return nread; } }</code>	
灰飞灰猪不会灰飞.烟灭	2018-05-31
老师, 带缓冲区的io流比nio哪一个性能更好?	
作者回复	2018-06-01
嗯, 文中提到过, 不能一概而论, 性能通常是特定场景下的比较才有意义	
mongo	2018-05-31
杨老师, 我也想请教, 目前为止您的其他文章都理解的很好, 到了上次专栏的NIO我理解的不是很好, 今天的这篇可以说懵圈了。到了这一步想突破, 应该往哪个方向? 我自己感觉是因为基于这两个底层原理的上层应用使用的时候观察的不够深入, 对原理反应的现象没有深刻感受, 就是所谓还没有摸清楚人家长什么样。所以接下来我会认真在使用基于这些原理实现的上层应用过程中不断深挖和观察, 比如认真学习dubbo框架(底层使用到了netty, netty的底层使用了NIO)来帮助我理解NIO。在这个过程中促进对dubbo的掌握, 以此良性循环。不知道方向对不对? 老师的学习方法是什么? 请老师指点避坑。学习方法不对的话时间成本太可怕。	
作者回复	2018-05-31
我觉得思路不错, 结合实践是非常好的; 我自身也仅仅是理论上理解, 并没有在大规模实践中踩坑, 实践中遇到细节的“坑”其实是宝贝, 所以你有更多优势; 本文从基础角度出发, 也是希望对其原理有个整体印象, 至少被面试刨根问底时, 可以有所准备, 毕竟看问题的角度是不同的	
夏洛克的教赎	2018-05-31
请问老师您有参与jdk的开发吗	
作者回复	2018-05-31
是的, 目前lead的团队主要是QE职责	
沈老师	2018-05-31
上面有两张说明普通copy和nio下的transfer, 我理解大致意思就是后者省去了切换到用户态的开销, 但想问一下前者为什么要设计这样的切换呢?是不是和你copy的数据类型有关?还望详释, 谢谢!	
作者回复	2018-05-31
抱歉, 这得问Mark R, 不清楚历史原因; 我理解大部分工作其实是需要用户态的, transfer是特定场景而非通用场景	
玲玲要学习	2018-06-28
堆外缓存是否与内核缓存是同一个东西?	
Miaozhe	2018-06-07
杨老师再问个问题, DirectByteBffer类为什么不能使用? 看代码它是继承自MappedByteBuffer.	
CC	2018-06-07
我Nio从没接触过, 很难受, 两年开发的	
作者回复	2018-06-07
不用担心, 是理解有难度吗?	
Miaozhe	2018-06-07
再问个问题, 在Java 8中, 对Byte Buffer有这样的描述, a byte buffer is either or non-direct. 我有点晕乎了, 在代码调试中isDirect是False 。	

作者回复	2018-06-07
你的bytebuffer怎么分配的？allocate？试试allocateDirect。 那段话我理解就是说 不是这个就是那个吧	
Miaozhe	2018-06-07
杨老师，问个问题，Byte Buffer对象什么时候被垃圾回收？	
作者回复	2018-06-07
依赖于cleaner，具体时候不好预测，在快满时会被调用system.gc触发ref处理，后续版本有所改进，至少不会出现，明明有空间，但并发分配会oom的问题	
jacky	2018-05-31
杨老师，如果显示调用system.gc会不会导致堆空间充足，但fullgc频繁的现象呢？导致应用经常停顿？	
作者回复	2018-06-01
肯定有副作用	
I am a psycho	2018-05-31
杨老师，我看1.8的源码中，files.copy共重载了4个方法，其中有三个调用的都是bio，有一个是您讲的native调用，而没有nio的transferTo。请问这是jdk9变成nio的吗？	
作者回复	2018-06-01
哦，现在机场，我平时工作在最新版本，现在是jdk11...	
正是那朵玫瑰	2018-05-31
可以具体讲一下MappedByteBuffer的原理和使用技巧么？	
灰飞灰猿不会灰飞.烟灭	2018-05-31
杨老师 我刚刚做个项目，上传文件到文件服务器，文件大概10M，经常上传失败。假如我上传的文件改成1M，就没这问题了。不知道什么原因，能提供个思路吗？谢谢	
作者回复	2018-06-01
有个建议，工程师在沟通故障时，可以收集下：出错信息；客户端、服务端配置；网络情况，比如是否有代理，等等。 至于思路，能否找到程序异常信息之类，做过哪些尝试将问题缩小范围？ 定位问题通常就是个不断缩小范围，排除不可能的过程。	
crazyone	2018-05-31
杨老师，Nio transfer 不一定快的场景是否有案例场景说明下？ 还有你说MappedByteBuffer本质上也是一个Direct Buffer，那它设计的目的和意义是什么？	
作者回复	2018-05-31
找个普通笔记本试试，stream那个往往更快...	
Cui	2018-05-31
Direct Buffer 生命周期内存地址都不会再发生更改，进而内核可以安全地对其进行访问—这里能提高性能的原因 是因为内存地址不变，没有锁争用吗？能否详细解答下？	
作者回复	2018-05-31
我理解不是锁的问题。寻址简单，才好更直接	
LenX	2018-05-31
请教老师： 1.经常看到 Java 进程的 RES 大小远超过设置的 Xmx，可以认为这就是 Direct Memory 的原因吗？如果是的话，可以简单的用堆实际占用的大小减去 RES 就是 Direct Memory 的大小吗？ 2.可以认为 Direct Memory 不论在什么情况下都不会引起 Full GC，Direct Memory 的回收只是在 Full GC（或调用 System.gc()）的时候顺带着回收下，是吗？	
作者回复	2018-05-31
1，一般不是，那东西有个默认大小的，metaspace codecache等等都会占用，后面有章节仔细分析 2，不是，它是利用sun.misc.Cleaner，实际表现有瑕疵，经常要更依赖system gc去触发引用处理，9和8u有改进，我会有详解	

