加微信:642945106 发送"赠送"领取赠送精品课程

发数字"2"获取众筹列表

下载APP 🙈

20 | 存储和并发: 万人群聊系统设计中的几个难点

2019-10-11 袁武林

即时消息技术剖析与实战

进入课程 >



讲述: 袁武林

时长 15:20 大小 14.04M



你好,我是袁武林。

我在场景篇的第 10 讲"自动智能扩缩容:直播互动场景中峰值流量的应对"中,分析了直 播互动场景中,容易出现瓶颈的原因主要在于: "直播间人数多,短时间内活跃度高,消息 的扇出量巨大"。

那么,对于同样属于多人互动的群聊场景来说,虽然在"群人数"等方面与高热度的直播间 相比要少一些,但由于同时开播的直播间数量一般不会太多,所以群在数量上的总体量级相 对要大得多,可能上百万个群同时会有消息收发的情况发生。因此,在整体的流量方面,群 聊场景的消息扇出也是非常大的。

而且和直播互动场景不太一样的是,直播互动中,热度高的直播活动持续时间都比较短,可以借助上云,来进行短时间的扩容解决,成本方面也比较可控;但群聊的场景,一般是流量总量高,但是峰值没有那么明显,靠扩容解决不太现实。因此,更多地需要我们从架构和设计层面来优化。

今天,我们就一起从架构设计层面,来聊一聊万人群聊系统中的几个难点,以及相应的解决方案。

群聊消息怎么存储?

首先来看一看群聊消息存储的问题。

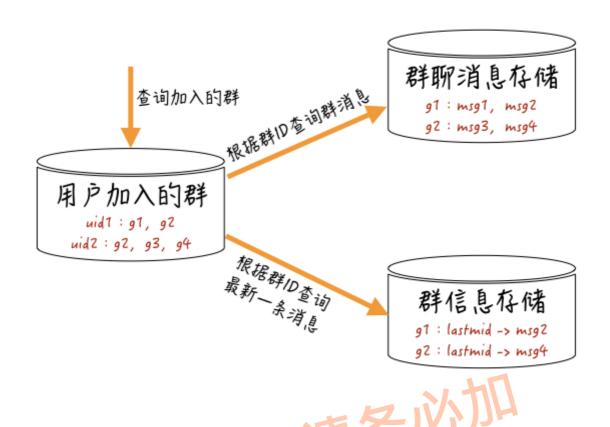
关于点对点聊天场景,我在第 2 课 "消息收发架构:为你的 App,加上实时通信功能"中也有讲到:我们在一条消息发出后,会针对消息收发的双方,各自存储一条索引,便于双方进行查询、删除、撤回等操作。

那么,对于群聊消息来说,是不是也需要给群里的每一个用户,都存储一条消息索引呢?

这里需要注意的是:对于点对点聊天来说,针对消息收发双方进行用户维度的索引存储,能便于后续会话维度的消息查看和离线消息的获取,但如果群聊场景也采取这种方式,那么假设一个群有一万个人,就需要针对这一万个人都进行这一条消息的存储,一方面会使写入并发量巨大,另一方面也存在存储浪费的问题。

所以,业界针对群聊消息的存储,一般采取"读扩散"的方式。也就是一条消息只针对群维度存储一次,群里用户需要查询消息时,都通过这个群维度的消息索引来获取。

用户查询群聊消息的大概流程, 你可以参考下图:



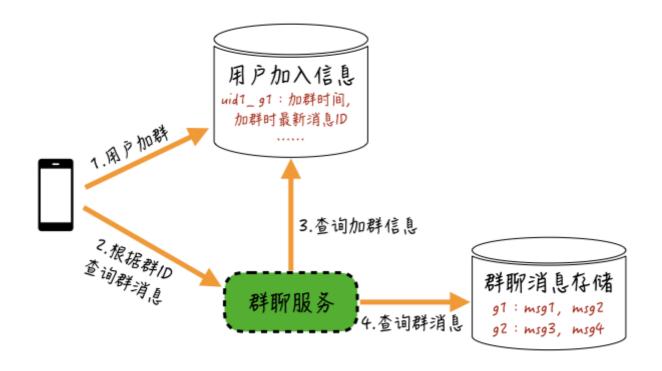
系统先查询这个用户加入的所有群,根据这些群的最新一条消息的 ID (消息 ID 与时间相关),或者最新一条消息的产生时间,来进行"最近联系人"维度的排序,再根据这些群 ID 获取每个群维度存储的消息。

怎么保证新加入群的用户只看到新消息?

群聊用户共用群维度的消息存储,能大幅降低用户维度消息的写入。

但这里有一个问题:如果群消息是共享的,怎么保证新加入群的用户看不到加群前的群聊消息呢?

解决这个问题其实比较简单,你可以采取下图这个方案:



我们只需要在用户加群的时候,记录一个"用户加群的信息",把用户加群时间、用户加群时该群最新一条消息的 ID 等信息存储起来,当用户查询消息时,根据这些信息来限制查询的消息范围就可以了。

单个用户删除消息怎么办?

除了新加群用户消息查询范围的问题,群消息共享存储方案在实现时,还有一个比较普遍的问题:如果群里的某一个用户删除了这个群里的某条消息,我们应该怎么处理?

首先,由于群消息是共用的,我们肯定不能直接删除群消息索引中的记录。

一个可行的办法是:在用户删除消息的时候,把这条被删除消息加入到当前用户和群维度的一个删除索引中;当用户查询消息时,我们对群维度的所有消息,以及对这个"用户和群维度"的删除索引进行聚合剔除就可以了。

同样的处理,你还可以用在其他一些私有类型的消息中。比如,只有自己能看到的一些系统提示类消息等。

未读数合并变更

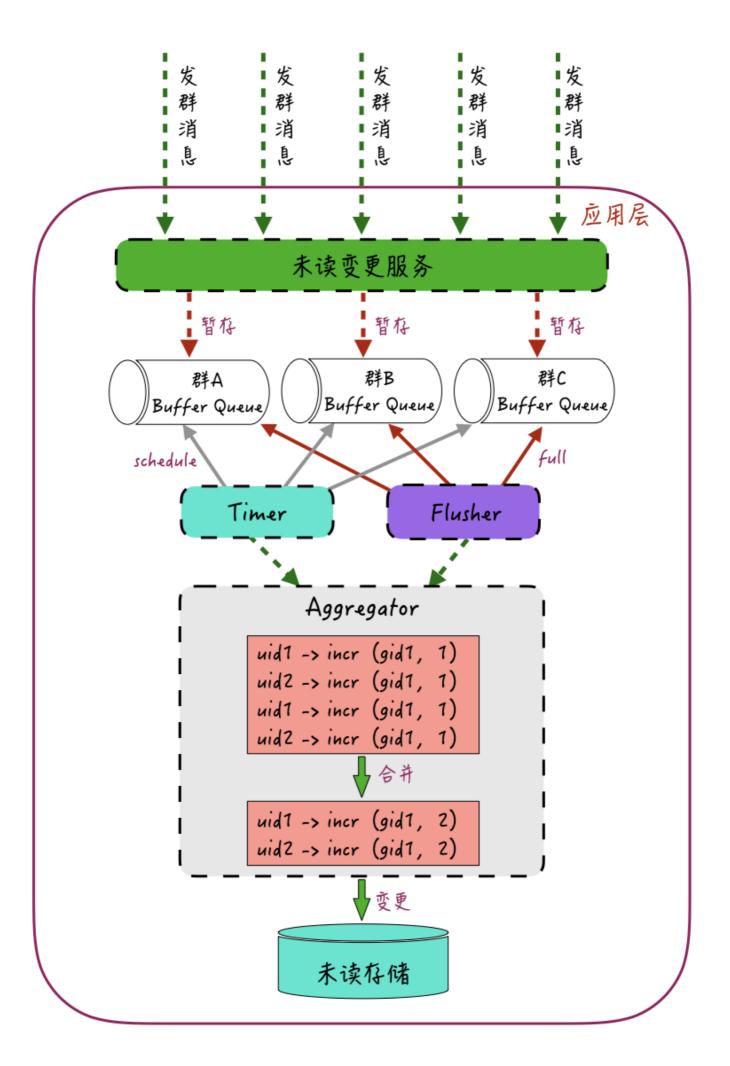
解决了群聊消息存储的问题,还有一个由于群聊消息高并发扇出而引起的问题。

我在 "07 | 分布式锁和原子性: 你看到的未读消息提醒是真的吗?" 这一篇课程中讲到 过:针对每一个用户,我们一般会维护两个未读数,用于记录用户在某个群的未读消息数和 所有未读数。

也就是说, 当群里有人发言时, 我们需要对这个群里的每一个人都进行"加未读"操作。因 此,对于服务端和未读数存储资源来说,整体并发的压力会随着群人数和发消息频率的增长 而成倍上升。

以一个 5000 人的群为例:假设这个群平均每秒有 10 个人发言,那么每秒针对未读资源的 变更 QPS 就是 5w; 如果有 100 个这样的群, 那么对未读资源的变更压力就是 500w, 所 以整体上需要消耗的资源是非常多的。

解决这个问题的一个可行方案是:在应用层对未读数采取合并变更的方式。来降低对存储资



未读变更服务接收群聊的加未读请求,将这些加未读请求按照群 ID 进行归类,并暂存到群 ID 维度的多个"暂存队列"中;这些"暂存队列"的请求会通过一个 Timer 组件和一个 Flusher 组件来负责处理。

Timer 组件负责定时刷新这些队列中的请求,比如,每一秒从这些"暂存队列"取出数据,然后交给 Aggregator 进行合并处理;Flusher 组件则会根据这些"暂存队列"的长度来进行刷新,比如,当队列长度到达 100 时,Flusher 就从队列中取出数据,再交给Aggregator 来进行合并处理。

所以,Timer 和 Flusher 的触发条件是:这些队列的请求中有任意一个到达,均会进行刷新操作。

提交给 Aggregator 的加未读请求会进行合并操作。比如针对群里的每一个用户,将多个归属于该群的加未读请求合并成一个请求,再提交给底层资源。

如上图所示,群 ID 为 gid1 里的用户 uid1 和 uid2,通过合并操作,由 4 次加未读操作 incr 1 合并成了各自一条的加未读操作 incr 2。

通过这种方式,就将加未读操作 QPS 降低了一半。如果每秒群里发消息的 QPS 是 10 的话,理论上我们通过这种"合并"的方式,能将 QPS 降低到 1/10。

当然,这里需要注意的是:由于加未读操作在应用层的内存中会暂存一定时间,因此会存在一定程度的加未读延迟的问题;而且如果此时服务器掉电或者重启,可能会丢失掉一部分加未读操作。

为了提升"合并变更"操作的合并程度,我们可以通过群 ID 哈希的方式,将某一个群的所有未读变更操作都路由到某一台服务器,这样就能够提升最终合并的效果。

离线 Buffer 只存消息 ID

通过"合并变更",我们解决了万人群聊系统中,未读数高并发的压力问题。

接下来我们看一下,在离线推送环节中,针对群聊场景还有哪些可优化的点。

我在第9课<u>"分布式一致性:让你的消息支持多终端漫游?"</u>中有讲到,为了解决用户离线期间收不到消息的问题,我们会在服务端按照接收用户维度,暂存用户离线期间的消息,

等该用户下次上线时再进行拉取同步。

这里的离线 Buffer 是用户维度的,因此对于群聊中的每一条消息,服务端都会在扇出后进行暂存。

假设是一个 5000 人的群,一条消息可能会暂存 5000 次,这样一方面对离线 Buffer 的压力会比较大,另外针对同一条消息的多次重复暂存,对资源的浪费也是非常大的。

要解决多次暂存导致离线 Buffer 并发压力大的问题,一种方案是可以参考"未读数合并变更"的方式,对群聊离线消息的存储也采用"合并暂存"进行优化,所以这里我就不再细讲了。

另一种解决方案是:我们可以对群聊离线消息的暂存进行限速,必要时可以丢弃一些离线消息的暂存,来保护后端资源。

因为通过"版本号的链表机制",我们可以在用户上线时发现"离线消息"不完整的问题,然后再从后端消息存储中重新分页获取离线消息,从而可以将一部分写入压力延迟转移到读取压力上来。

不过这里你需要注意的是:这种降级限流方式存在丢失一些操作信令的问题,是有损降级,所以非必要情况下尽量不用。

另外,针对群聊消息重复暂存的问题,我们可以只在离线 Buffer 中暂存 "消息 ID",不暂存消息内容,等到真正下推离线消息的时候,再通过消息 ID 来获取内容进行下推,以此优化群聊消息对离线 Buffer 资源过多占用的情况。

离线消息批量 ACK

在群聊离线消息场景中,还有一个相对并发量比较大的环节就是:离线消息的 ACK 处理。

我在<u>"04 | ACK 机制:如何保证消息的可靠投递?"</u>这节课中讲到,我们会通过 ACK 机制来保证在线消息和离线消息的可靠投递。但是对于群的活跃度较高的情况来说,当用户上线时,服务端针对这个群的离线消息下推量会比较大。

以微博场景中的超大规模的粉丝群为例:本来群内的用户就已经比较活跃了,如果该群隶属的明星突然空降进来,可能会导致大量离线用户被激活,同一时间会触发多个用户的离线消

息下推和这些离线消息的 ACK; 针对离线消息接收端的 ACK 回包,服务端需要进行高并发的处理,因而对服务端压力会比较大。

但实际上,由于群聊离线消息的下推发生在用户刚上线时,这个时候的连接刚建立,稳定性比较好,一般消息下推的成功率是比较高的,所以对 ACK 回包处理的及时性其实不需要太高。

因此,一种优化方案是: **针对离线消息接收端进行批量 ACK**。

参照 TCP 的 Delay ACK (延迟确认) 机制,我们可以在接收到离线推送的消息后,"等待"一定的时间,如果有其他 ACK 包需要返回,那么可以对这两个回包的 ACK 进行合并,从而降低服务端的处理压力。

需要注意的是:接收端的 Delay ACK,可能会在一定程度上加剧消息重复下推的概率。比如,ACK 由于延迟发出,导致这时的服务端可能会触发超时重传,重复下推消息。

针对这个问题,我们可以通过接收端去重来解决,也并不影响用户的整体体验。

不记录全局的在线状态

群聊场景下的超大消息扇出,除了会加大对离线消息的资源消耗,也会对消息的在线下推造成很大的压力。

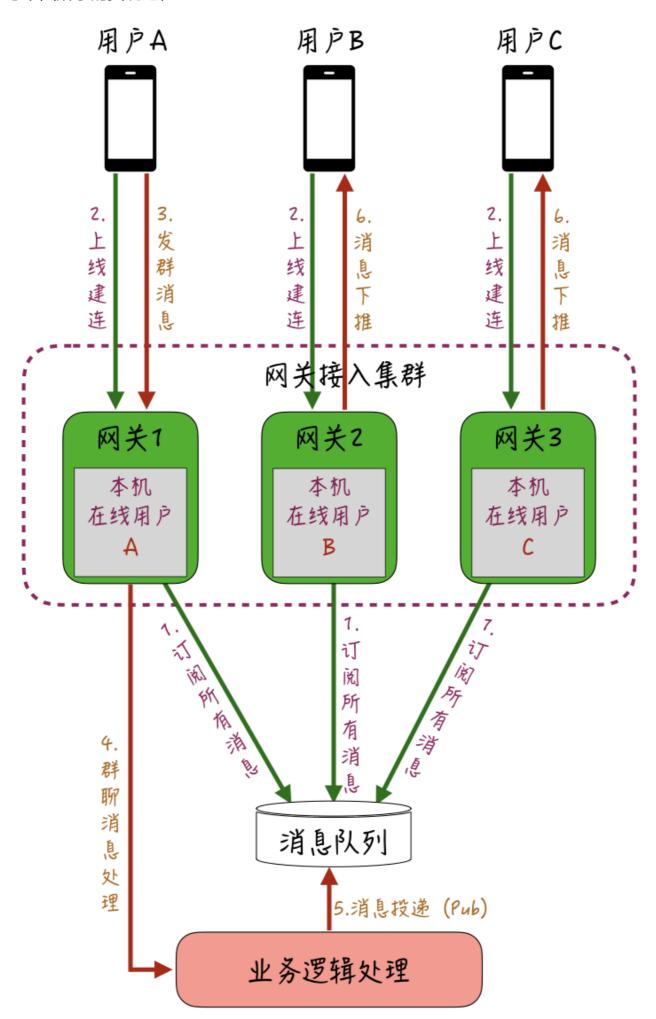
举个例子:在点对点聊天场景中,我们通常会在用户上线时,记录一个"用户连接所在的网关机"的在线状态,而且为了和接入服务器解耦,这个在线状态一般会存储在中央资源中;当服务端需要下推消息时,我们会通过这个"中央的在线状态"来查询接收方所在的接入网关机,然后把消息投递给这台网关机,来进行最终消息的下推。

在群聊场景中,很多实现也会采用类似方式进行在线消息的精准下推,这种方案在群人数较少的时候是没问题的,但是当群成员规模很大时,这种方式就会出现瓶颈。

一个瓶颈在于,用户上线时对"在线状态"的写入操作;另一个瓶颈点在于,服务端有消息下推时,对"在线状态"的高并发查询。

因此,针对万人群聊的场景,我们可以采取类似直播互动中的优化方式,不维护全局的中央"在线状态",而是让各网关机"自治",来维护接入到本机的连接和群的映射。你可以

参考下图所示的实现过程:



比如同一个群的用户 A、B、C,分别通过网关机 1、2、3 上线建立长连,处理建连请求时,网关机 1、2、3 会分别在各自的本地内存维护当前登录的用户信息。

上线完成后,用户 A 在群里发了一条消息,业务逻辑处理层会针对这条消息进行处理,查询出当前这条消息所归属群的全部用户信息,假设查询到这个群一共有 3 人,除去发送方用户 A,还有用户 B 和用户 C。

然后业务逻辑处理层把消息扇出到接收人维度,投递到全局的消息队列中;每一台网关机在启动后都会订阅这个全局的 Topic,因此都能获取到这条消息;接着,各网关机查询各自本地维护的"在线用户"的信息,把归属本机的用户的消息,通过长连下推下去。

通过这种方式,消息下推从"全局的远程依赖"变成了"分片的本地内存依赖",性能上会快很多,避免了服务端维护全局在线状态的资源开销和压力。

小结

今天的课程,我主要是分析了一些在万人群聊场景中比较突出和难解决的问题,并给出了针对性的应对方案。比如以下几种:

针对群聊消息的存储,我们可以从点对点的"写扩散"优化成"读扩散",以解决存储写入并发大和资源开销大的问题;

针对高热度的群带来的"高并发未读变更"操作,我们可以通过**应用层的"合并变更"**,来缓解未读资源的写入压力;

对于离线消息的优化,我们只需要存储消息 ID,避免重复的消息内容存储浪费离线 Buffer 资源,还可以参考 TCP 的 Delay ACK 机制,**在接收方层面进行批量 ACK**,降低服务端的处理并发压力;

对于单聊场景中依赖"中央全局的在线状态",来进行消息下推的架构瓶颈,我们可以在 群聊场景中优化成"**网关机本地自治维护**"的方式,以此解决高并发下推时,依赖全局资 源容易出现瓶颈的问题,从而提升群聊消息在线下推的性能和稳定性。

针对大规模群聊系统的架构优化,一直是即时消息场景中非常重要和必要的部分,也是体现我们架构能力和功底的环节。

今天课程中介绍的针对万人群聊系统优化的一些应对方案,很多都具备普适性,比如"未读合并变更"的方案,实际上也能应用在很多有写入瓶颈的业务上(如 DB 的写入瓶颈),在

微博的线上业务中,目前也被大范围使用。你也可以看一看,自己的业务中是否也有类似可 优化的场景,可以尝试来参考这个方案进行优化。

最后给大家留一个思考题: **点对点消息的在线下推,也适合采用"网关机自治维护本地在线** 状态"的方式吗?说说你的看法吧。

以上就是今天课程的内容,欢迎你给我留言,我们可以在留言区一起讨论,感谢你的收听,我们下期再见。



新版升级:点击「探请朋友读」,20位好友免费读,邀请订阅更有现金奖励。

© 版权归极客邦科技所有,未经许可不得传播售卖。 页面已增加防盗追踪,如有侵权极客邦将依法追究其法律责任。

上一篇 19 | 端到端Trace: 消息收发链路的监控体系搭建

下一篇 21 | 期末实战: 为你的简约版IM系统, 加上功能

精选留言 (9)



思考题:



看情况考虑。

不好的地方:

所有网关机都要从消息队列消费这条数据,但最终只有一台机器处理,比较浪费处理资 源。对这条消息而言本来可以直接下推,结果要多经过了网关机,实时性可能会受到大... 展开٧

> 凸 1



clip

2019-10-11

群聊的私有类型消息是不是要采用补齐而不是剔除的逻辑? 因为加了一条仅自己可见的消 息给其他人都创建不可见索引就得不偿失了。

展开٧

<u>____</u>2





zhxh

2019-10-11

如果通过订阅的方式,那么这条消息应该也需要把群成员列表带给网关吧,否则网关怎么 筛选,可是万人群成员比较多,会导致这个消息包比较大,如果不带成员列表信息到网 关,那么要求用户在和网关建立连接的时候,就要把自己加入的群列表信息带过来,绑定 到网关,这样逻辑似乎和网关耦合比较严重,老师能详细解释一下么

展开٧

<u></u>1





黄海

2019-10-14

请袁老师看一下这样的方案行吗: 把各台网关机上的在线群(在线群成员数>0) 的群 uid 作 为 key, 把网关机的消息队列 topic 作为 value, 写入 redis set 中, 发送群消息时, 根据 key 群 uid 从 redis set 中查出群成员分布在哪些网关机上,然后通过消息队列,精准的向 这些网关机推送群聊消息

展开٧





墙角儿的花

2019-10-11

老师 用websocket做长链接通信在网络较好情况下没什么问题 但在弱网下如2g 3g下就会 频繁掉线,但是微信却做的这么好,地铁里仍然很稳定,它走的绝对不是websocket,它 怎么做到的这么稳定通畅呢? 有什么资料可以查看学习吗。

展开٧

<u>____2</u>





老师,想请问下:在用户删除消息的时候,把这条被删除消息加入到当前用户和群维度的一个删除索引中,这一步不是很明白

展开٧

□1 **△**



万人群聊,系统是维护了万个TCP链接吗?

展开٧

₽2 **₽**



老师上午好、有些疑惑想跟您确认一下,消息多终端漫游,为解决用户离线期间收不到消息的问题,我们会在服务端按照接收用户维度,暂存用户离线期间的消息,等该用户下次上线时再进行拉取同步。

- 1、这里的同步,实际上是把服务端的消息同步到客户端,客户端也保存这些消息吧?
- 2、假如用户重新安装了APP,把客户端保存的数据也清空了,像这种情况下,一般处理… 展开~





墙角儿的花

2019-10-11

群聊信息如果不采用收发箱的方式存储,碰见钉钉这种需要记录查看一条群消息哪些成员已阅,哪些未阅,就无能为力了

展开٧

₽2 **₽**