

# 45|位图：如何实现网页爬虫中的URL去重功能？

网页爬虫是搜索引擎中的非常重要的系统，负责爬取几十亿、上百亿的网页。爬虫的工作原理是，通过解析已经爬取页面中的网页链接，然后再爬取这些链接对应的网页。而同一个网页链接有可能被包含在多个页面中，这就会导致爬虫在爬取的过程中，重复爬取相同的网页。如果你是一名负责爬虫的工程师，你会如何避免这些重复的爬取呢？

最容易想到的方法就是，我们记录已经爬取的网页链接（也就是URL），在爬取一个新的网页之前，我们拿它的链接，在已经爬取的网页链接列表中搜索。如果存在，那就说明这个网页已经被爬取过了；如果不存在，那就说明这个网页还没有被爬取过，可以继续去爬取。等爬取到这个网页之后，我们将这个网页的链接添加到已经爬取的网页链接列表了。

思路非常简单，我想你应该很容易就能想到。不过，我们该如何记录已经爬取的网页链接呢？需要用什么样的数据结构呢？

## 算法解析

关于这个问题，我们可以先回想下，是否可以用我们之前学过的数据结构来解决呢？

这个问题要处理的对象是网页链接，也就是URL，需要支持的操作有两个，添加一个URL和查询一个URL。除了这两个功能性的要求之外，在非功能性方面，我们还要求这两个操作的执行效率要尽可能高。除此之外，因为我们处理的是上亿的网页链接，内存消耗会非常大，所以在存储效率上，我们要尽可能地高效。

我们回想一下，满足这些条件的数据结构有哪些呢？显然，散列表、红黑树、跳表这些动态数据结构，都能支持快速地插入、查找数据，但是对内存消耗方面，是否可以接受呢？

我们拿散列表来举例。假设我们要爬取10亿个网页（像Google、百度这样的通用搜索引擎，爬取的网页可能会更多），为了判重，我们把这10亿网页链接存储在散列表中。你来估算下，大约需要多少内存？

假设一个URL的平均长度是64字节，那单纯存储这10亿个URL，需要大约60GB的内存空间。因为散列表必须维持较小的装载因子，才能保证不会出现过多的散列冲突，导致操作的性能下降。而且，用链表法解决冲突的散列表，还会存储链表指针。所以，如果将这10亿个URL构建成散列表，那需要的内存空间会远大于60GB，有可能会超过100GB。

当然，对于一个大型的搜索引擎来说，即便是100GB的内存要求，其实也不算太高，我们可以采用分治的思想，用多台机器（比如20台内存是8GB的机器）来存储这10亿网页链接。这种分治的处理思路，我们讲过很多次了，这里就不详细说了。

对于爬虫的URL去重这个问题，刚刚讲到的分治加散列表的思路，已经是可以在实实在在工作的了。不过，作为一个有追求的工程师，我们应该考虑，在添加、查询数据的效率以及内存消耗方面，我们是否还有进一步的优化空间呢？

你可能会说，散列表中添加、查找数据的时间复杂度已经是 $O(1)$ ，还能有进一步优化的空间吗？实际上，我们前面也讲过，时间复杂度并不能完全代表代码的执行时间。大 $O$ 时间复杂度表示法，会忽略掉常数、系数和低阶，并且统计的对象是语句的频度。不同的语句，执行时间也是不同的。时间复杂度只是表示执行时间随数据规模的变化趋势，并不能度量在特定的数据规模下，代码执行时间的多少。

如果时间复杂度中原来的系数是10，我们现在能够通过优化，将系数降为1，那在时间复杂度没有变化的情况下，执行效率就提高了10倍。对于实际的软件开发来说，10倍效率的提升，显然是一个非常值得的优化。

如果我们用基于链表的方法解决冲突问题，散列表中存储的是URL，那当查询的时候，通过哈希函数定位到某个链表之后，我们还需要依次比对每个链表中

的URL。这个操作是比较耗时的，主要有两点原因。

一方面，链表中的结点在内存中不是连续存储的，所以不能一下子加载到CPU缓存中，没法很好地利用到CPU高速缓存，所以数据访问性能方面会打折扣。

另一方面，链表中的每个数据都是URL，而URL不是简单的数字，是平均长度为64字节的字符串。也就是说，我们要让待判重的URL，跟链表中的每个URL，做字符串匹配。显然，这样一个字符串匹配操作，比起单纯的数字比对，要慢很多。所以，基于这两点，执行效率方面肯定是有优化空间的。

对于内存消耗方面的优化，除了刚刚这种基于散列表的解决方案，貌似没有更好的法子了。实际上，如果要想内存方面有明显的节省，那就得换一种解决方案，也就是我们今天要着重讲的这种存储结构，布隆过滤器（Bloom Filter）。

在讲布隆过滤器前，我要先讲一下另一种存储结构，位图（BitMap）。因为，布隆过滤器本身就是基于位图的，是对位图的一种改进。

我们先来看一个跟开篇的问题非常类似，但稍微简单的问题。我们有1千万个整数，整数的范围在1到1亿之间。如何快速查找某个整数是否在这1千万个整数中呢？

当然，这个问题还是可以用散列表来解决。不过，我们可以使用一种比较“特殊”的散列表，那就是位图。我们申请一个大小为1亿、数据类型为布尔类型（true或者false）的数组。我们将这1千万个整数作为数组下标，将对应的数组值设置成true。比如，整数5对应下标为5的数组值设置为true，也就是array[5]=true。

当我们查询某个整数K是否在这1千万个整数中的时候，我们只需要将对应的数组值array[K]取出来，看是否等于true。如果等于true，那说明1千万整数中包含这个整数K；相反，就表示不包含这个整数K。

不过，很多语言中提供的布尔类型，大小是1个字节的，并不能节省太多内存空间。实际上，表示true和false两个值，我们只需要用一个二进制位（bit）就可以了。那如何通过编程语言，来表示一个二进制位呢？

这里就要用到位运算了。我们可以借助编程语言中提供的数据类型，比如int、long、char等类型，通过位运算，用其中的某个位表示某个数字。文字描述起来有点儿不好理解，我把位图的代码实现写了出来，你可以对照着代码看下，应该就能看懂了。

```
public class BitMap {
    private char[] bytes;
    private int nbits;

    public BitMap(int nbits) {
        this.nbits = nbits;
        this.bytes = new char[nbits/8+1];
    }

    public void set(int k) {
        if (k > nbits) return;
        int byteIndex = k / 8;
        int bitIndex = k % 8;
        bytes[byteIndex] |= (1 << bitIndex);
    }

    public boolean get(int k) {
        if (k > nbits) return false;
        int byteIndex = k / 8;
        int bitIndex = k % 8;
        return (bytes[byteIndex] & (1 << bitIndex)) != 0;
    }
}
```

从刚刚位图结构的讲解中，你应该可以发现，位图通过数组下标来定位数据，所以，访问效率非常高。而且，每个数字用一个二进制位来表示，在数字范围不大的情况下，所需要的内存空间非常节省。

比如刚刚那个例子，如果用散列表存储这1千万的数据，数据是32位的整型数，也就是需要4个字节的存储空间，那总共至少需要40MB的存储空间。如果我们通过位图的话，数字范围在1到1亿之间，只需要1亿个二进制位，也就是12MB左右的存储空间就够了。

关于位图，我们就讲完了，是不是挺简单的？不过，这里我们有个假设，就是数字所在的范围不是很大。如果数字的范围很大，比如刚刚那个问题，数字范围不是1到1亿，而是1到10亿，那位图的大小就是10亿个二进制位，也就是120MB的大小，消耗的内存空间，不降反增。

这个时候，布隆过滤器就要出场了。布隆过滤器就是为了解决刚刚这个问题，对位图这种数据结构的一种改进。

还是刚刚那个例子，数据个数是1千万，数据的范围是1到10亿。布隆过滤器的做法是，我们仍然使用一个1亿个二进制大小的位图，然后通过哈希函数，对数字进行处理，让它落在这1到1亿范围内。比如我们把哈希函数设计成 $f(x)=x\%n$ 。其中， $x$ 表示数字， $n$ 表示位图的大小（1亿），也就是，对数字跟位图的大小进行取模求余。


不过，你肯定会说，哈希函数会存在冲突的问题啊，一亿零一和1两个数字，经过你刚刚那个取模求余的哈希函数处理之后，最后的结果都是1。这样我就无法区分，位图存储的是1还是一亿零一了。

为了降低这种冲突概率，当然我们可以设计一个复杂点、随机点的哈希函数。除此之外，还有其它方法吗？我们来看布隆过滤器的处理方法。既然一个哈希函数可能会存在冲突，那用多个哈希函数一块儿定位一个数据，是否能降低冲突的概率呢？我来具体解释一下，布隆过滤器是怎么做的。


我们使用 $K$ 个哈希函数，对同一个数字进行求哈希值，那会得到 $K$ 个不同的哈希值，我们分别记作 $X_{\{1\}}$ ， $X_{\{2\}}$ ， $X_{\{3\}}$ ，...， $X_{\{K\}}$ 。我们把这 $K$ 个数字作为位图中的下标，将对应的 $BitMap[X_{\{1\}}]$ ， $BitMap[X_{\{2\}}]$ ， $BitMap[X_{\{3\}}]$ ，...， $BitMap[X_{\{K\}}]$ 都设置成true，也就是说，我们用 $K$ 个二进制位，来表示一个数字的存在。

当我们要查询某个数字是否存在的时候，我们用同样的 $K$ 个哈希函数，对这个数字求哈希值，分别得到 $Y_{\{1\}}$ ， $Y_{\{2\}}$ ， $Y_{\{3\}}$ ，...， $Y_{\{K\}}$ 。我们看这 $K$ 个哈希值，对应位图中的数值是否都为true，如果都是true，则说明，这个数字存在，如果有其中任意一个不为true，那就说明这个数字不存在。

将163存储进位图




查询237是否存在




对于两个不同的数字来说，经过一个哈希函数处理之后，可能会产生相同的哈希值。但是经过 $K$ 个哈希函数处理之后， $K$ 个哈希值都相同的概率就非常低了。尽管采用 $K$ 个哈希函数之后，两个数字哈希冲突的概率降低了，但是，这种处理方式又带来了新的问题，那就是容易误判。我们看下面这个例子。

将146,196存储进位图



查询177是否存在



布隆过滤器的误判有一个特点，那就是，它只会对存在的情况有误判。如果某个数字经过布隆过滤器判断不存在，那说明这个数字真的不存在，不会发生误判；如果某个数字经过布隆过滤器判断存在，这个时候才有可能误判，有可能并不存在。不过，只要我们调整哈希函数的个数、位图大小跟要存储数字的个数之间的比例，那就可以将这种误判的概率降到非常低。

尽管布隆过滤器会存在误判，但是，这并不影响它发挥大作用。很多场景对误判有一定的容忍度。比如我们今天要解决的爬虫判重这个问题，即便一个没有被爬取过的网页，被误判为已经被爬取，对于搜索引擎来说，也并不是什么大事情，是可以容忍的，毕竟网页太多了，搜索引擎也不可能100%都爬取到。

弄懂了布隆过滤器，我们今天的爬虫网页去重的问题，就很简单了。

我们用布隆过滤器来记录已经爬取过的网页链接，假设需要判重的网页有10亿，那我们可以用一个10倍大小的位图来存储，也就是100亿个二进制位，换算成字节，那就是大约1.2GB。之前我们用散列表判重，需要至少100GB的空间。相比来讲，布隆过滤器在存储空间的消耗上，降低了非常多。

那我们再来看下，利用布隆过滤器，在执行效率方面，是否比散列表更加高效呢？

布隆过滤器用多个哈希函数对同一个网页链接进行处理，CPU只需要将网页链接从内存中读取一次，进行多次哈希计算，理论上讲这组操作是CPU密集型的。而在散列表的处理方式中，需要读取散列冲突拉链的多个网页链接，分别跟待判重的网页链接，进行字符串匹配。这个操作涉及很多内存数据的读取，所以是内存密集型的。我们知道CPU计算可能是要比内存访问更快速的，所以，理论上讲，布隆过滤器的判重方式，更加快速。

## 总结引申

今天，关于搜索引擎爬虫网页去重问题的解决，我们从散列表讲到位图，再讲到布隆过滤器。布隆过滤器非常适合这种不需要100%准确的、允许存在小概率误判的大规模判重场景。除了爬虫网页去重这个例子，还有比如统计一个大型网站的每天的UV数，也就是每天有多少用户访问了网站，我们就可以使用布隆过滤器，对重复访问的用户，进行去重。

我们前面讲到，布隆过滤器的误判率，主要跟哈希函数的个数、位图的大小有关。当我们往布隆过滤器中不停地加入数据之后，位图中不是true的位置就越来越少了，误判率就越来越高了。所以，对于无法事先知道要判重的数据个数的情况，我们需要支持自动扩容的功能。

当布隆过滤器中，数据个数与位图大小的比例超过某个阈值的时候，我们就重新申请一个新的位图。后面来的新数据，会被放置到新的位图中。但是，如果我们要判断某个数据是否在布隆过滤器中已经存在，我们就需要查看多个位图，相应的执行效率就降低了一些。

位图、布隆过滤器应用如此广泛，很多编程语言都已经实现了。比如Java中的BitSet类就是一个位图，Redis也提供了BitMap位图类，Google的Guava工具包提供了BloomFilter布隆过滤器的实现。如果你感兴趣，你可以自己去研究下这些实现的源码。

## 课后思考

1. 假设我们有1亿个整数，数据范围是从1到10亿，如何快速并且省内存地给这1亿个数据从小到大排序？
2. 还记得我们在[哈希函数（下）](#)讲过的利用分治思想，用散列表以及哈希函数，实现海量图库中的判重功能吗？如果我们允许小概率的误判，那是否可以用今天的布隆过滤器来解决呢？你可以参照我们当时的估算方法，重新估算下，用布隆过滤器需要多少台机器？

欢迎留言和我分享，也欢迎点击“请朋友读”，把今天的内容分享给你的好友，和他一起讨论、学习。





# 数据结构与算法之美

为工程师量身打造的数据结构与算法私教课

王争

前 Google 工程师



新版升级：点击「👤请朋友读」，10位好友免费读，邀请订阅更有**现金**奖励。

## 精选留言：

- DreamYe 2019-01-09 01:02:48  
bloom filter: False is always false. True is maybe true. [14赞]
- 五岳寻仙 2019-01-09 07:54:11

## 课后思考题<sup>1</sup>

传统的做法：1亿个整数，存储需要400M空间，排序时间复杂度最优  $N \times \log(N)$

使用位图算法：数字范围是1到10亿，用位图存储125M就够了，然后将1亿个数字依次添加到位图中，然后再将位图按下标从小到大输出值为1的下标，排序就完成了，时间复杂度为  $N$  [7赞]

- 传说中的成大大 2019-01-09 13:43:18

1亿个整数 如果完全读入内存大约是0.4G的样子 可以直接快排排序

通过位图方式开辟一个十亿大小的位图缩小到0.125g的样子,虽然数字只有一亿个,但是我们却要检查1到10亿之间的数字是否存在再输出即可达到排序 [3赞]

- 公号-代码荣耀 2019-01-12 09:15:14

在线上环境，我们采用redis的set进行去重，效果还是不错的 [2赞]

- ban 2019-01-11 18:08:26

这个char代码最好还是用图解比较好理解，纯代码看不懂。

我这里有另外一个位的图解计算过程，再去看代码，你就会秒懂

<https://mp.weixin.qq.com/s/xxauNrJY9HlVNVrLrL5j2hg> [2赞]

- 煦暖 2019-01-11 11:44:21

争哥，位图的代码理解了好久还没懂(; ' ^ `)，能加几行注释吗？？ [2赞]

作者回复2019-01-14 10:01:52

好的 我去补充下

- spark 2019-01-09 16:57:59

位图代码的实现一开始没看懂，请教了下身边一位大神同事才搞懂，原来char类型存储数字的时候，只占1个字节，也就是8位。所以计算的时候都是除8或者模8。希望我的回答可以帮助其他跟我一样基础薄弱的同学，共同进步 [2赞]

- 越过山丘 2019-01-10 09:02:51

第一题，数字重复了，有什么好方法处理吗 [1赞]

作者回复2019-01-10 09:54:41

对于重复的 可以再维护一个小的散列表 记录出现次数超过1次的数据以及对应的个数

- 阮雅 2019-01-09 21:38:16

王争哥，您好。你画这个图，用的啥软件画的啊？ 比普通的黑白图更容易理解。望求解！感激不尽！ [1赞]



45|位图：如何实现网页爬虫中的URL去重功能？

作者回复2019-01-10 10:01:13

ipad paper

- spark 2019-01-09 17:36:43

思考题1:用10亿个位的位图存储这1亿个数，然后直接按脚标从0到10亿顺序遍历整个位图，如果位为1，则打印脚标，打印出来的就是排好序的1亿个数字

思考题2:用位图的话。一个机器应该就够了 [1赞]

- marvinle 2019-01-09 14:33:53

老师，按照你的讲解我写了一个简单的布隆过滤器，使用了3个简单的哈希函数，判错率在0.9左右

不知道是否是属于偏高了，这是代码，可以的话帮忙看看是否正确<https://github.com/MarvinLe/tools/tree/master/BloomFilter> [1赞]

作者回复2019-01-10 10:11:41

判错率太高了 哈希函数不够随机均匀？位图不够大？

- Kudo 2019-01-09 13:33:44

直观上感觉位图有点像学排序时桶的概念，所以使用位图也可以实现类似于桶排序的效率。 [1赞]

- Sharry 2019-01-09 09:11:44

这个位图很精妙，因为编程语言没有提供bit类型，所以使用byte进行位运算的方式，巧妙的利用每一位，以达到减少内存开辟的消耗的问题 [1赞]

- 千千 2019-01-20 20:07:28

位图的设计实属精妙，极大的减少了所需分配的空间，在位图的代码中选用的是char作为单位来存储数据，而一个char字符在java中占一个字节也就是8位的空间，而这8位可对应为8个数据，也就是说开辟的bytes数组大小可减小到原来的1/8。既然可以char字符才存储数据，那么是不是也能用int、long呢？对应的数组空间便可减小到原来的1/32、1/64，但是如果这样做，对应的取模和相除操作便会增加运算时间，这何尝又不是用空间来换取时间呢。

- orcababyface 2019-01-17 16:34:21

王老师，对于您写的BitMap我有几个问题请教一下：

0 Java的char数据类型占16位，是不是把代码中的8都改成16更合适？

1 set方法我觉得是不是能够set为true或false，您写的set就是只set为true。

2 11行和18行if内是不是应该为k > nbits-1 更合适？

- 一修 2019-01-13 14:00:57

老师 对于这段话我的理解不是这样。比如我们今天要解决的爬虫判重这个问题，即便一个没有被爬取过的网页，被误判为已经被爬取，对于搜索引擎来说，也并不是什么大事情，是可以容忍的，毕竟网页太多了，搜索引擎也不可能 100% 都爬取到。实际上布隆过滤器的特点是不存在位图中的一定不会判错。所以结果是对于已经看爬过的网页可能判断为没爬过，这样多爬一次不过是浪费点带宽 而漏爬似乎有点不太好？不知道理解对不对

2019-01-14 10:07:53

45|位图：如何实现网页爬虫中的URL去重功能？

作者回复

应该是判定为存在的 不一定存在 你理解错了

- Alexis何春光 2019-01-13 13:10:32

哦不好意思，`bitmap`那里没问题了，我把 `<<` 这个操作符的左右看颠倒了。有疑问的朋友可以搜索一下Java 里 `bit manipulation`

- Alexis何春光 2019-01-13 13:06:22

`bitmap`那里，如果以`nbits`为31的`bitmap`来说。`set(31) : byte[3] = 00001110`. 然后如果我查找 `get(30): return 00001110 & 00001100 = 00001100 !=0, return true`, 就不对了呀？可否解释一下，谢谢！

- Alexis何春光 2019-01-13 12:27:51

老师，你提到100gb的内存要求就要用分布式了，但是我在网上搜到很多服务器的内存甚至可以达到tb级别，只有pc的内存才至多16gb，请问您了解的一般的服务器的内存是多少呢？

- likun 2019-01-12 15:06:29

`char`类型是两个字节 应该除以16吧？

作者回复2019-01-17 15:31:19

嗯嗯 我改下，我跟c/c++搞混了