30 | 时代之风(上): HTTP/2特性概览

2019-08-05 Chrono

透视HTTP协议 进入课程>



讲述: Chrono 时长 11:03 大小 12.66M



在第 14 讲里,我们看到 HTTP 有两个主要的缺点:安全不足和性能不高。

刚结束的"安全篇"里的 HTTPS,通过引入 SSL/TLS 在安全上达到了"极致",但在性能提升方面却是乏善可陈,只优化了握手加密的环节,对于整体的数据传输没有提出更好的改进方案,还只能依赖于"长连接"这种"落后"的技术(参见<mark>第 17 讲</mark>)。

所以,在 HTTPS 逐渐成熟之后,HTTP 就向着性能方面开始"发力",走出了另一条进化的道路。

在第1讲的 HTTP 历史中你也看到了,"秦失其鹿,天下共逐之",Google 率先发明了 SPDY 协议,并应用于自家的浏览器 Chrome,打响了 HTTP 性能优化的"第一枪"。

随后互联网标准化组织 IETF 以 SPDY 为基础,综合其他多方的意见,终于推出了 HTTP/1 的继任者,也就是今天的主角"HTTP/2",在性能方面有了一个大的飞跃。

为什么不是 HTTP/2.0

你一定很想知道,为什么 HTTP/2 不像之前的"1.0""1.1"那样叫"2.0"呢?

这个也是很多初次接触 HTTP/2 的人问的最多的一个问题, 对此 HTTP/2 工作组特别给出了解释。

他们认为以前的"1.0""1.1"造成了很多的混乱和误解,让人在实际的使用中难以区分差异,所以就决定 HTTP 协议不再使用小版本号(minor version),只使用大版本号(major version),从今往后 HTTP 协议不会出现 HTTP/2.0、2.1,只会有"HTTP/2""HTTP/3"……

这样就可以明确无误地辨别出协议版本的"跃进程度",让协议在一段较长的时期内保持稳定,每当发布新版本的 HTTP 协议都会有本质的不同,绝不会有"零敲碎打"的小改良。

兼容 HTTP/1

由于 HTTPS 已经在安全方面做的非常好了,所以 HTTP/2 的唯一目标就是改进性能。

但它不仅背负着众多的期待,同时还背负着 HTTP/1 庞大的历史包袱,所以协议的修改必须小心谨慎,兼容性是首要考虑的目标,否则就会破坏互联网上无数现有的资产,这方面 TLS 已经有了先例(为了兼容 TLS1.2 不得不进行"伪装")。

那么,HTTP/2 是怎么做的呢?

因为必须要保持功能上的兼容,所以 HTTP/2 把 HTTP 分解成了"语义"和"语法"两个部分,"语义"层不做改动,与 HTTP/1 完全一致(即 RFC7231)。比如请求方法、URI、状态码、头字段等概念都保留不变,这样就消除了再学习的成本,基于 HTTP 的上层应用也不需要做任何修改,可以无缝转换到 HTTP/2。

特别要说的是,与 HTTPS 不同,HTTP/2 没有在 URI 里引入新的协议名,仍然用"http"表示明文协议,用"https"表示加密协议。

这是一个非常了不起的决定,可以让浏览器或者服务器去自动升级或降级协议,免去了选择的麻烦,让用户在上网的时候都意识不到协议的切换,实现平滑过渡。

在"语义"保持稳定之后,HTTP/2 在"语法"层做了"天翻地覆"的改造,完全变更了HTTP报文的传输格式。

头部压缩

首先, HTTP/2 对报文的头部做了一个"大手术"。

通过"进阶篇"的学习你应该知道,HTTP/1 里可以用头字段"Content-Encoding"指定 Body 的编码方式,比如用 gzip 压缩来节约带宽,但报文的另一个组成部分——Header 却被无视了,没有针对它的优化手段。

由于报文 Header 一般会携带"User Agent""Cookie""Accept""Server"等许多固定的头字段,多达几百字节甚至上千字节,但 Body 却经常只有几十字节(比如 GET 请求、204/301/304响应),成了不折不扣的"大头儿子"。更要命的是,成千上万的请求响应报文里有很多字段值都是重复的,非常浪费,"长尾效应"导致大量带宽消耗在了这些冗余度极高的数据上。

所以,HTTP/2 把"**头部压缩**"作为性能改进的一个重点,优化的方式你也肯定能想到,还是"压缩"。

不过 HTTP/2 并没有使用传统的压缩算法,而是开发了专门的"**HPACK**"算法,在客户端和服务器两端建立"字典",用索引号表示重复的字符串,还采用哈夫曼编码来压缩整数和字符串,可以达到 50%~90% 的高压缩率。

二进制格式

你可能已经很习惯于 HTTP/1 里纯文本形式的报文了,它的优点是"一目了然",用最简单的工具就可以开发调试,非常方便。

但 HTTP/2 在这方面没有"妥协",决定改变延续了十多年的现状,不再使用肉眼可见的 ASCII 码,而是向下层的 TCP/IP 协议"靠拢",全面采用二进制格式。

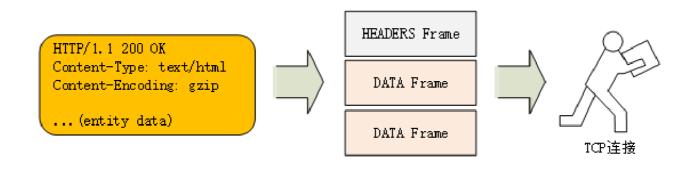
这样虽然对人不友好,但却大大方便了计算机的解析。原来使用纯文本的时候容易出现多义性,比如大小写、空白字符、回车换行、多字少字等等,程序在处理时必须用复杂的状态机,效率低,还麻烦。

而二进制里只有"0"和"1",可以严格规定字段大小、顺序、标志位等格式,"对就是对,错就是错",解析起来没有歧义,实现简单,而且体积小、速度快,做到"内部提效"。

以二进制格式为基础, HTTP/2 就开始了"大刀阔斧"的改革。

它把 TCP 协议的部分特性挪到了应用层,把原来的"Header+Body"的消息"打散"为数个小片的**二进制"帧"**(Frame),用"HEADERS"帧存放头数据、"DATA"帧存放实体数据。

这种做法有点像是 "Chunked" 分块编码的方式 (参见<mark>第 16 讲</mark>) , 也是 "化整为零" 的思路 , 但 HTTP/2 数据分帧后 "Header+Body" 的报文结构就完全消失了 , 协议看到的只是一个个的 "碎片" 。



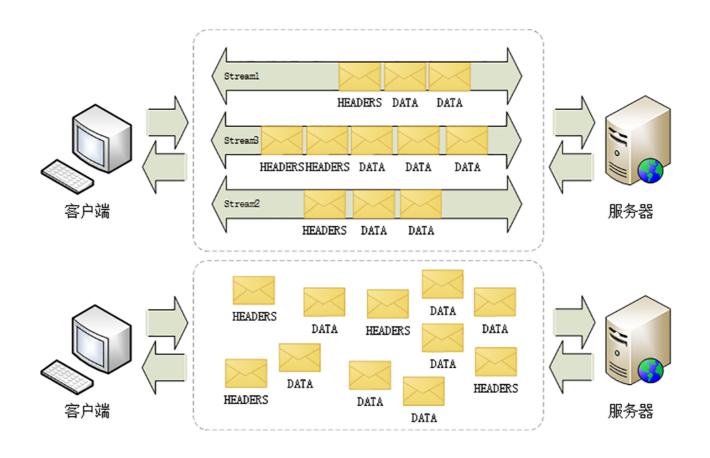
虚拟的"流"

消息的"碎片"到达目的地后应该怎么组装起来呢?

HTTP/2 为此定义了一个"流"(Stream)的概念,**它是二进制帧的双向传输序列**,同一个消息往返的帧会分配一个唯一的流 ID。你可以想象把它成是一个虚拟的"数据流",在里面流动的是一串有先后顺序的数据帧,这些数据帧按照次序组装起来就是 HTTP/1 里的请求报文和响应报文。

因为"流"是虚拟的,实际上并不存在,所以 HTTP/2 就可以在一个 TCP 连接上用"流"同时发送多个"碎片化"的消息,这就是常说的"**多路复用**"(Multiplexing)——多个往返通信都复用一个连接来处理。

在"流"的层面上看,消息是一些有序的"帧"序列,而在"连接"的层面上看,消息却是 乱序收发的"帧"。多个请求/响应之间没有了顺序关系,不需要排队等待,也就不会再 出现"队头阻塞"问题,降低了延迟,大幅度提高了连接的利用率。



为了更好地利用连接,加大吞吐量,HTTP/2 还添加了一些控制帧来管理虚拟的"流",实现了优先级和流量控制,这些特性也和 TCP 协议非常相似。

HTTP/2 还在一定程度上改变了传统的"请求-应答"工作模式,服务器不再是完全被动地响应请求,也可以新建"流"主动向客户端发送消息。比如,在浏览器刚请求 HTML 的时候就提前把可能会用到的 JS、CSS 文件发给客户端,减少等待的延迟,这被称为"**服务器推送**"(Server Push,也叫 Cache Push)。

强化安全

出于兼容的考虑, HTTP/2 延续了 HTTP/1 的"明文"特点,可以像以前一样使用明文传输数据,不强制使用加密通信,不过格式还是二进制,只是不需要解密。

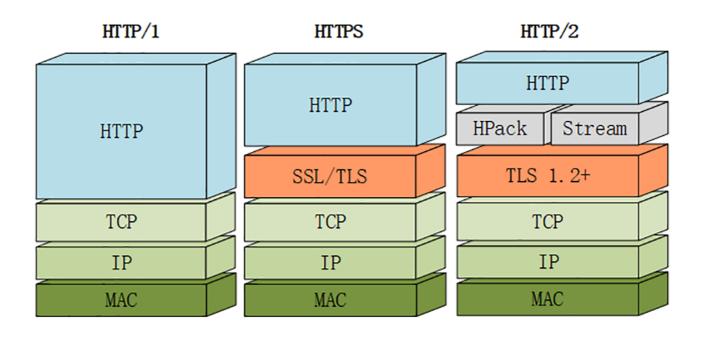
但由于 HTTPS 已经是大势所趋,而且主流的浏览器 Chrome、Firefox 等都公开宣布只支持加密的 HTTP/2,所以"事实上"的 HTTP/2 是加密的。也就是说,互联网上通常所能见到的 HTTP/2 都是使用"https"协议名,跑在 TLS 上面。

为了区分"加密"和"明文"这两个不同的版本,HTTP/2协议定义了两个字符串标识符:"h2"表示加密的HTTP/2,"h2c"表示明文的HTTP/2,多出的那个字母"c"的意思是"clear text"。

在 HTTP/2 标准制定的时候(2015年)已经发现了很多 SSL/TLS 的弱点,而新的 TLS1.3 还未发布,所以加密版本的 HTTP/2 在安全方面做了强化,要求下层的通信协议必须是 TLS1.2 以上,还要支持前向安全和 SNI,并且把几百个弱密码套件列入了"黑名单",比如 DES、RC4、CBC、SHA-1 都不能在 HTTP/2 里使用,相当于底层用的是"TLS1.25"。

协议栈

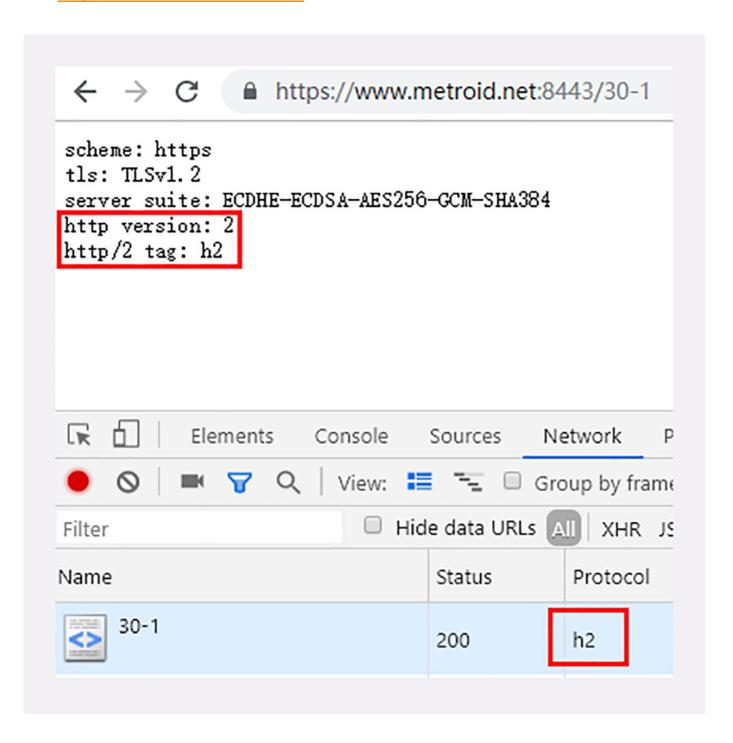
下面的这张图对比了 HTTP/1、HTTPS 和 HTTP/2 的协议栈,你可以清晰地看到,HTTP/2 是建立在"HPack" "Stream" "TLS1.2"基础之上的,比 HTTP/1、HTTPS 复杂了一些。



虽然 HTTP/2 的底层实现很复杂,但它的"语义"还是简单的 HTTP/1,之前学习的知识不会过时,仍然能够用得上。

我们的实验环境在新的域名"www.metroid.net"上启用了HTTP/2协议,你可以把之前"进阶篇""安全篇"的测试用例都走一遍,再用Wireshark抓一下包,实际看看HTTP/2的效果和对老协议的兼容性(例如"http://www.metroid.net/11-1")。

在今天这节课专用的 URI "/30-1" 里,你还可以看到服务器输出了 HTTP 的版本号 "2" 和标识符 "h2",表示这是加密的 HTTP/2,如果改用 "https://www.chrono.com/30-1" 访问就会是 "1.1" 和空。



你可能还会注意到 URI 里的一个小变化,端口使用的是"8443"而不是"443"。这是因为 443 端口已经被"www.chrono.com"的 HTTPS 协议占用,Nginx 不允许在同一个端口上根据域名选择性开启 HTTP/2,所以就不得不改用了"8443"。

小结

今天我简略介绍了 HTTP/2 的一些重要特性,比较偏重理论,下一次我会用 Wireshark 抓包,具体讲解 HTTP/2 的头部压缩、二进制帧和流等特性。

- 1. HTTP 协议取消了小版本号, 所以 HTTP/2 的正式名字不是 2.0;
- 2. HTTP/2 在"语义"上兼容 HTTP/1,保留了请求方法、URI 等传统概念;
- 3. HTTP/2 使用 "HPACK" 算法压缩头部信息,消除冗余数据节约带宽;
- 4. HTTP/2 的消息不再是 "Header+Body" 的形式,而是分散为多个二进制 "帧";
- 5. HTTP/2 使用虚拟的"流"传输消息,解决了困扰多年的"队头阻塞"问题,同时实现了"多路复用",提高连接的利用率;
- 6. HTTP/2 也增强了安全性,要求至少是 TLS1.2,而且禁用了很多不安全的密码套件。

课下作业

- 1. 你觉得明文形式的 HTTP/2 (h2c) 有什么好处, 应该如何使用呢?
- 2. 你觉得应该怎样理解 HTTP/2 里的"流", 为什么它是"虚拟"的?
- 3. 你能对比一下 HTTP/2 与 HTTP/1、HTTPS 的相同点和不同点吗?

欢迎你把自己的学习体会写在留言区,与我和其他同学一起讨论。如果你觉得有所收获,也欢迎把文章分享给你的朋友。

ccccccccccccccccc

课外小贴士

- O1 在早期还有一个"HTTP-NG"(HTTP Next Generation)项目,最终失败了。
- 02 HTTP/2 的"前身"SPDY 在压缩头部时使用了 gzip, 但发现会受到"CRIME"攻击, 所以 开发了专用的压缩算法 HPACK。
- 03 HTTP/2 里的"流"可以实现 HTTP/1 里的"管道"(pipeline) 功能,而且综合性能更好,所以"管道"在 HTTP/2 里就被废弃了。
- O4 如果你写过 Linux 程序,用过 epoll,就应该知道 epoll 也是一种"多路复用",不过它是"I/O Multiplexing"。
- O5 HTTP/2 要求必须实现的密码套件是 "TLS_ECDHE_RSA_WITH_AES_128_GCM_SHA256", 比 TLS1.2 默认的 "TLS_RSA_WITH_AES_128_CBC_SHA"的安全强度高了很多。

06 实验环境的"www.metroid.net"启用了RSA和ECC双证书,在浏览器里可以看到实际连接时用的会是ECC证书。另外,这个域名还用到了第29讲里的重定向跳转技术,使用301跳转,把"80/443"端口的请求重定向到HTTP/2的"8443"。



© 版权归极客邦科技所有,未经许可不得传播售卖。页面已增加防盗追踪,如有侵权极客邦将依法追究其法律责任。

精选留言(1)





magicnum

2019-08-05

h2c优点是性能,不需要TLS握手以及加解密。可以通过curl工具构造h2c请求;

h2的流是虚拟的因为它是使用帧传输数据的,相同streamid的帧组成了虚拟消息以及流;

相同点:都是基于tcp或TLS,并且是基于请求-响应模型,schema还是http或https不会有

http2。

不同点:h2使用二进制传输消息并且通过HPACK压缩请求头,实现流多路复用、服务器...

展开~

